

# LSTAT 2040 - TP 2 : Solutions

## Estimation ponctuelle

### Exercice 1

- (a) Comme  $E[W] = (a + b)\mu$ ,  $W$  est sans biais pour  $\mu$  dès que  $a + b = 1$ .
- (b) On cherche les valeurs de  $a$  et de  $b$  telles que  $a + b = 1$  et qui minimisent le risque quadratique de  $W$  donné par

$$\text{MSE}(W) = \text{Bias}(W)^2 + \text{Var}(W) = \text{Var}(W) = a^2\sigma^2 + 4b^2\sigma^2 = (a^2 + 4b^2)\sigma^2.$$

Il faut donc minimiser la fonction  $(a, b) \in \mathbb{R}^2 \mapsto a^2 + 4b^2$  sous la contrainte  $b = 1 - a$ . En substituant la contrainte dans le problème, on trouve que l'on doit minimiser la fonction  $a \in \mathbb{R} \mapsto a^2 + 4(1 - a)^2 = 5a^2 - 8a + 4$ , et par dérivation, on voit que son minimum est atteint en  $a = 4/5$ . On déduit la valeur de  $b = 1/5$  de la contrainte. Le choix  $(a, b) = (4/5, 1/5)$  est donc la meilleur choix à effectuer si l'on souhaite un estimateur sans biais pour  $\mu$  de variance minimale.

### Exercice 2

Il faut montrer que

$$E[X_{(1)}] \rightarrow \theta, \quad n \rightarrow \infty.$$

Afin de calculer l'espérance, on commence par trouver la distribution de  $X_{(1)}$ . Pour cela, on observe que pour tout  $x \geq \theta$ ,

$$\Pr(X_{(1)} \geq x) = \Pr(X_1 \geq x)^n,$$

car l'échantillon est iid. Dès lors, pour  $x \geq \theta$ ,

$$f_{X_{(1)}}(x) = \frac{d}{dx} \Pr(X_{(1)} \leq x) = n \Pr(X_1 \geq x)^{n-1} f(x, \theta).$$

Par intégration, on trouve  $\Pr(X_1 \geq x) = \exp(-(x - \theta))$  pour  $x \geq \theta$ . Comme  $f_{X_{(1)}} \equiv 0$  sur  $(-\infty, \theta)$ , on déduit

$$f_{X_{(1)}}(x) = n \exp(-n(x - \theta)) \mathbf{I}(x \geq \theta).$$

De là, on calcule

$$E[X_{(1)}] = \int_{\mathbb{R}} x f_{X_{(1)}}(x) dx = \theta + \frac{1}{n},$$

et la conclusion suit.

### Exercice 3

Pour  $\hat{\theta}_1$ , on calcule facilement que

$$E[\hat{\theta}_1] = \frac{3}{2} E[\bar{X}_n] = \frac{3}{2} E[X_1] = \theta.$$

Pour  $\hat{\theta}_2$ , on a

$$E[\hat{\theta}_2] = \frac{2n+1}{2n} E[X_{(n)}],$$

et nous avons besoin de  $f_{X_{(n)}}$  pour calculer l'espérance. On a pour tout  $0 < x < \theta$ ,

$$f_{X_{(n)}}(x) = \frac{d}{dx} \Pr(X_{(n)} \leq x) = \frac{d}{dx} \Pr(X_1 \leq x)^n = n \Pr(X_1 \leq x)^{n-1} f(x, \theta) = \frac{2n}{\theta^{2n}} x^{2n-1},$$

et  $f_{X_{(n)}} \equiv 0$  ailleurs. On déduit

$$\mathbb{E}[X_{(n)}] = \int_{\mathbb{R}} x f_{X_{(n)}}(x) dx = \frac{2n}{2n+1} \theta,$$

et donc  $\mathbb{E}[\hat{\theta}_2] = \theta$ .

Pour les variances, on a

$$\text{Var}[\hat{\theta}_1] = \frac{9}{4} \text{Var}[\bar{X}_n] = \frac{9}{4n} \text{Var}[X_1] = \frac{\theta^2}{8n}.$$

Pour  $\hat{\theta}_2$ , on a

$$\text{Var}[\hat{\theta}_2] = \frac{(2n+1)^2}{(2n)^2} \text{Var}[X_{(n)}]$$

où

$$\text{Var}[X_{(n)}] = \int_{\mathbb{R}} x^2 f_{X_{(n)}}(x) dx - \left( \int_{\mathbb{R}} x f_{X_{(n)}}(x) dx \right)^2.$$

Après calculs, on trouve  $\text{Var}[\hat{\theta}_2] = \frac{\theta^2}{4n(n+1)}$ . Dès lors, dès que  $n > 1$ , on aura  $\text{Var}[\hat{\theta}_2] < \text{Var}[\hat{\theta}_1]$ .

## Exercice 4

- (a) Comme  $\mathbb{E}[X_1] = 1/\lambda$ , on propose l'estimateur  $\hat{\lambda} = 1/\bar{X}_n$ .
- (b) Comme suggéré dans le premier indice, il faut remarquer que

$$\hat{\lambda} = \frac{n}{\sum_{i=1}^n X_i}, \quad \sum_{i=1}^n X_i \sim \text{Gamma}(n, \lambda).$$

Dès lors, pour tout  $x \geq 0$ ,

$$\begin{aligned} f_{\hat{\lambda}}(x) &= \frac{d}{dx} \Pr\left(\frac{n}{\sum_{i=1}^n X_i} \leq x\right) = \frac{d}{dx} \Pr\left(\sum_{i=1}^n X_i \geq \frac{n}{x}\right) \\ &= \frac{n}{x^2} f_{\sum_{i=1}^n X_i}(n/x) = \frac{\lambda^n}{(n-1)!} \left(\frac{n}{x}\right)^n \frac{1}{x} \exp(-\lambda n/x). \end{aligned}$$

On peut alors calculer le risque quadratique de l'estimateur

$$\text{MSE}[\hat{\lambda}] = \text{Bias}[\hat{\lambda}]^2 + \text{Var}[\hat{\lambda}].$$

Pour le calcul du biais, on doit obtenir  $\mathbb{E}[\hat{\lambda}]$ . On a,

$$\mathbb{E}[\hat{\lambda}] = \frac{\lambda^n}{(n-1)!} n^n \int_0^\infty x^{-n} \exp(-\lambda n/x) dx = \frac{\lambda n}{(n-1)!} \int_0^\infty u^{n-2} \exp(-u) du,$$

où la seconde égalité est obtenue par le changement de variable  $u = \lambda n/x$ . Par le second indice, on remarque que  $\int_0^\infty u^{n-2} \exp(-u) du = \Gamma(n-1) = (n-2)!$ . On déduit

$$\mathbb{E}[\hat{\lambda}] = \lambda \frac{n}{n-1}.$$

Pour la variance, un calcul similaire donne

$$\text{Var}[\hat{\lambda}] = \frac{n^2 \lambda^2}{(n-1)^2 (n-2)}.$$

On déduit que le risque quadratique est donné par

$$\text{MSE}[\hat{\lambda}] = \frac{(n+2)\lambda^2}{(n-1)(n-2)}.$$

(c) On voit directement que, comme  $E[\hat{\lambda}] = \lambda n / (n - 1)$ , l'estimateur

$$\tilde{\lambda} = \frac{n-1}{n} \hat{\lambda},$$

sera sans biais pour  $\lambda$ .

## Exercice 5

(a) Intuitivement, on a envie de proposer

$$\hat{a} = X_{(1)} \quad \text{et} \quad \hat{b} = X_{(n)}.$$

(b) Par des raisonnements similaires à ce que l'on a déjà fait dans les exercices précédents, on trouve

$$f_{\hat{a}}(x) = \frac{n}{(b-a)^n} (b-x)^{n-1} \mathbf{I}(a \leq x \leq b)$$

et

$$f_{\hat{b}}(x) = \frac{n}{(b-a)^n} (x-a)^{n-1} \mathbf{I}(a \leq x \leq b).$$

(c) En utilisant les densités trouvées au point précédent et l'indice pour calculer les intégrales, on trouve

$$\text{Bias}[\hat{a}] = \frac{b-a}{n+1} \quad \text{Var}[\hat{a}] = \frac{n(b-a)^2}{(n+1)^2(n+2)}$$

et

$$\text{Bias}[\hat{b}] = -\frac{b-a}{n+1} \quad \text{Var}[\hat{b}] = \frac{n(b-a)^2}{(n+1)^2(n+2)}.$$

Le signe des biais peut s'expliquer comme suit : puisque toutes les données  $X_i$  de l'échantillon sont strictement supérieures à  $a$  et inférieures à  $b$  avec probabilité 1, le minimum de celles-ci  $X_{(1)} = \hat{a}$  aura tendance à sur-estimer  $a$ , le biais est donc positif, tandis que  $X_{(n)} = \hat{b}$  aura tendance à sous-estimer  $b$ , le biais est donc négatif.

(d) Dans le cas où  $b = 2a$ , on a, par nos calculs précédents,

$$E[\alpha X_{(1)} + \beta X_{(n)}] = a \left( \alpha \left( 2 - \frac{n}{n+1} \right) + \beta \left( 2 - \frac{1}{n+1} \right) \right).$$

Si on veut que l'estimateur soit sans biais pour  $a$ , il faut donc choisir  $(\alpha, \beta)$  tel que

$$\alpha \left( 2 - \frac{n}{n+1} \right) + \beta \left( 2 - \frac{1}{n+1} \right) = 1,$$

autrement dit, pour une valeur de  $\alpha$ , il faut prendre

$$\beta = \frac{n+1-\alpha(n+2)}{2n+1}.$$

## Exercice 6

(a) On calcule

$$\text{MSE}[\hat{p}_1] = \text{Bias}[\hat{p}_1]^2 + \text{Var}[\hat{p}_1] = 0^2 + \frac{p(1-p)}{n} = \frac{p(1-p)}{n}$$

et

$$\text{MSE}[\hat{p}_2] = \text{Bias}[\hat{p}_2]^2 + \text{Var}[\hat{p}_2] = \left( \frac{1-2p}{n+2} \right)^2 + \frac{np(1-p)}{(n+2)^2} = \frac{(1-2p)^2 + np(1-p)}{(n+2)^2}.$$

(b) Il faut résoudre l'inégalité  $\text{MSE}[\hat{p}_1] < \text{MSE}[\hat{p}_2]$  pour  $p$ . On trouve que cette inégalité est satisfaite pour

$$p < \frac{1}{2} - \sqrt{\frac{n+1}{8n+4}} \quad \text{ou} \quad p > \frac{1}{2} + \sqrt{\frac{n+1}{8n+4}}.$$

## Exercice 7

- (a) Notons que les variables aléatoires  $I(X_i \leq x)$  sont iid et distribuées selon une distribution  $\text{Be}(F(x))$  puisqu'elle ne prennent que les valeurs 0 ou 1 et la probabilité de "succès" est

$$\mathbb{E}[I(X_i \leq x)] = \Pr(X_i \leq x) = F(x).$$

Dès lors, on trouve

$$\mathbb{E}[\widehat{F}_n(x)] = \mathbb{E}[I(X_i \leq x)] = F(x)$$

et l'estimateur est sans biais. Pour calculer sa MSE, on calcule

$$\text{MSE}[\widehat{F}_n(x)] = \text{Var}[\widehat{F}_n(x)] = \frac{\text{Var}[I(X_1 \leq x)]}{n} = \frac{F(x)(1 - F(x))}{n}.$$

- (b) Le point  $x \in \mathbb{R}$  où la MSE de  $\widehat{F}_n(x)$  est maximale est le point  $x^*$  solution du problème

$$x^* = \underset{x \in \mathbb{R}}{\text{argmax}} \frac{F(x)(1 - F(x))}{n} = \underset{x \in \mathbb{R}}{\text{argmax}} F(x)(1 - F(x)).$$

Si on note  $p^* = F(x^*) \in [0, 1]$ , alors  $p^*$  satisfait

$$p^* = \underset{p \in [0, 1]}{\text{argmax}} p(1 - p) = 1/2,$$

où le problème peut être résolu par dérivation. On trouve alors que  $x^*$  est tel que  $F(x^*) = 1/2$ , c'est-à-dire,  $x^*$  est la médiane de  $F$ .

## Exercice 8

- (a) Par définition, le risque associé à  $\widehat{\theta}_k = X - k$  est

$$\mathbb{E}[L(\widehat{\theta}_k, \theta)] = \int_{\mathbb{R}} L(z, \theta) f_{\widehat{\theta}_k}(z) dz.$$

Puisque  $X \sim N(\theta, 1)$ , on a  $\widehat{\theta}_k = X - k \sim N(\theta - k, 1)$ . Donc, l'intégrale vaut

$$\begin{aligned} & \int_{\mathbb{R}} L(z, \theta) \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(z - (\theta - k))^2\right) dz \\ &= \int_{-\infty}^{\theta} b(\theta - z) \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(z - (\theta - k))^2\right) dz + \int_{\theta}^{\infty} a(z - \theta) \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(z - (\theta - k))^2\right) dz. \end{aligned}$$

On considère le même changement de variable  $x = z - (\theta - k)$ . On trouve alors,

$$\begin{aligned} & \int_{-\infty}^k b(k - x) \phi(x) dx + \int_k^{\infty} a(x - k) \phi(x) dx \\ &= b \left( k\Phi(k) + \int_{-\infty}^k -x\phi(x) dx \right) + a \left( -\int_k^{\infty} -x\phi(x) dx - k(1 - \Phi(k)) \right) \\ &= b \left( k\Phi(k) + \int_{-\infty}^k \phi'(x) dx \right) + a \left( -\int_k^{\infty} \phi'(x) dx - k(1 - \Phi(k)) \right) \\ &= b(k\Phi(k) + \phi(k)) + a(\phi(k) - k(1 - \Phi(k))) \\ &= (a + b)[\phi(k) + k\Phi(k)] - ka. \end{aligned}$$

- (b) Le valeur de  $k^*$  minimisant le risque satisfait

$$\frac{d(a + b)[\phi(k) + k\Phi(k)] - ka}{dk}(k^*) = (a + b)\Phi(k^*) - a = 0.$$

En résolvant l'équation, on trouve donc

$$k^* = \Phi^{-1} \left( \frac{a}{a+b} \right).$$

Notons qu'en particulier, si on avait  $a = b$  et que la fonction de perte était symétrique par rapport aux sous-estimations et aux sur-estimations de  $\theta$ , on aurait  $k^* = \Phi^{-1}(0.5) = 0$ . Le risque minimal est donné par

$$(a+b)[\phi(k^*) + k^*\Phi(k^*)] - k^*a = (a+b)\phi \left( \Phi^{-1} \left( \frac{a}{a+b} \right) \right).$$