

LSTAT 2040 - TP 7 : Solutions

Tests d'hypothèse

Exercice 1

(a) On rappelle que

$$\Lambda_n = \frac{\sup_{\lambda \geq \lambda_0} L_n(\lambda)}{\sup_{\lambda} L_n(\lambda)}.$$

On calcule pour tout $\lambda > 0$,

$$L_n(\lambda) = \prod_{i=1}^n \frac{\lambda^{X_i}}{X_i!} \exp(-\lambda) = \frac{\lambda^{\sum_{i=1}^n X_i}}{\prod_{i=1}^n X_i!} \exp(-n\lambda),$$

d'où l'on déduit

$$\ell_n(\lambda) = -n\lambda + \sum_{i=1}^n X_i \log(\lambda) - \sum_{i=1}^n \log(X_i!).$$

Dès lors, l'équation

$$\partial_{\lambda} \ell_n(\lambda) = -n + \frac{\sum_{i=1}^n X_i}{\lambda} = 0$$

n'admet qu'une unique solution donnée par

$$\lambda = \bar{X}_n.$$

Puisque pour tout $\lambda > 0$,

$$\partial_{\lambda}^2 \ell_n(\lambda) = -\frac{\sum_{i=1}^n X_i}{\lambda^2} < 0,$$

on déduit que le MLE de λ est donné par

$$\hat{\lambda}_{\text{MLE}} := \bar{X}_n.$$

On déduit également de la stricte concavité de la vraisemblance que le MLE contraint à la région $H_0 = \{\lambda \geq \lambda_0\}$ vaut $\hat{\lambda}_{\text{MLE}}$ si ce dernier est plus grand que λ_0 et vaut λ_0 sinon. On déduit que

$$\begin{aligned} \Lambda_n &= \begin{cases} \frac{L_n(\lambda_0)}{L_n(\hat{\lambda}_{\text{MLE}})} & \text{si } \hat{\lambda}_{\text{MLE}} \leq \lambda_0 \\ 1 & \text{sinon} \end{cases} \\ &= \begin{cases} \exp(T_n - n\lambda_0) \left(\frac{n\lambda_0}{T_n}\right)^{T_n} & \text{si } T_n \leq n\lambda_0 \\ 1 & \text{si } T_n > n\lambda_0, \end{cases} \end{aligned}$$

où l'on a posé $T_n := \sum_{i=1}^n X_i$.

(b) Soit $c \in (0, 1)$. Définissons $g : (0, n\lambda_0] \rightarrow (0, 1]$ par $g(t) = \exp(t - n\lambda_0)(n\lambda_0/t)^t$. Alors, on a que la région de rejet est donnée par

$$\{\Lambda_n \leq c\} = \{g(T_n) \leq c\}.$$

Montrons que la fonction g est croissante. Pour cela, puisque le logarithme est une transformation croissante, on peut simplement montrer que la composée $\log \circ g$ est croissante. On calcule pour tout $t \in (0, n\lambda_0]$,

$$\partial_t \log(g(t)) = \partial_t \left\{ t - n\lambda_0 + t \log \left(\frac{n\lambda_0}{t} \right) \right\} = \log \left(\frac{n\lambda_0}{t} \right) \geq 0.$$

On déduit que g est croissante et donc que la région de rejet vaut

$$\{g(T_n) \leq c\} = \{T_n \leq a\}, \quad a \in (0, n\lambda_0].$$

Soit $\alpha \in (0, 1)$. Le test sera de niveau α si

$$\sup_{\lambda \geq \lambda_0} P(T_n \leq a(\alpha) | \lambda) \leq \alpha,$$

i.e., la probabilité de rejeter H_0 si le vrai paramètre est dans H_0 est au maximum de α . Soit $\lambda \geq \lambda_0$. Puisque $T_n | \lambda \sim \text{Poi}(n\lambda)$, on a pour tout $x \in [0, \infty)$,

$$P(T_n \leq x | \lambda) \leq P(T_n \leq x | \lambda_0),$$

d'où l'on déduit que

$$\sup_{\lambda \geq \lambda_0} P(T_n \leq a(\alpha) | \lambda) = P(T_n \leq a(\alpha) | \lambda_0).$$

Dès lors, si l'on choisit $a(\alpha)$ comme étant le quantile d'ordre α d'une Poisson $\text{Poi}(n\lambda_0)$, on est sûr que le test sera de niveau α .

(c) Pour de telles valeurs, on a $a(0.05) = 39$ (obtenu via la commande `qpois(0.05, lambda = 25*2)` sur R). Dès lors, $t_n = 38$ appartient à la région de rejet et l'on rejette H_0 .

(d) Avec les nouvelles hypothèses, on aurait obtenu que la statistique de test du LRT exact est donnée par

$$\Lambda_n = g(T_n),$$

pour n'importe quelle valeur de la statistique T_n . Ainsi, puisque la fonction g est décroissante sur la région $[n\lambda_0, \infty)$, ce qui se voit directement de notre calcul de dérivée au point (a), on aurait eu que la région de rejet s'exprime sous la forme

$$\{\Lambda_n \leq c\} = \{g(T_n) \leq c\} = \{T_n \leq a\} \cup \{T_n \geq b\},$$

pour $0 < a < n\lambda_0 < b < \infty$. Dès lors, pour obtenir un test de niveau $\alpha \in (0, 1)$, on aurait du prendre $a(\alpha)$ et $b(\alpha)$ comme les quantiles d'ordre $\alpha/2$ et $1 - \alpha/2$ d'une Poisson $\text{Poi}(n\lambda_0)$. Avec les données du point (c), on aurait alors trouvé $a(0.05) = 37$ et $b(0.05) = 64$, et on aurait pas pu conclure au rejet de l'hypothèse H_0 (bien que les données sous-jacentes à l'obtention de la statistique observée $t_n = 38$ aient été simulées avec un paramètre dans la région H_1).

Exercice 2

(a) On rappelle que

$$\Lambda_n = \frac{\sup_{\pi \leq \pi_0} L_n(\pi)}{\sup_{\pi} L_n(\pi)}.$$

On calcule pour tout $\pi \in (0, 1)$,

$$L_n(\pi) = \prod_{i=1}^n \pi^{X_i} (1 - \pi)^{1-X_i} = \pi^{\sum_{i=1}^n X_i} (1 - \pi)^{n - \sum_{i=1}^n X_i},$$

d'où l'on déduit

$$\ell_n(\pi) = \left(\sum_{i=1}^n X_i \right) \log(\pi) + \left(n - \sum_{i=1}^n X_i \right) \log(1 - \pi).$$

Dès lors, l'équation

$$\partial_{\pi} \ell_n(\pi) = \frac{\sum_{i=1}^n X_i}{\pi} - \frac{n - \sum_{i=1}^n X_i}{1 - \pi} = 0$$

n'admet qu'une unique solution donnée par

$$\pi = \bar{X}_n.$$

Puisque pour tout $\pi \in (0, 1)$

$$\partial_\pi^2 \ell_n(\pi) = -\frac{\sum_{i=1}^n X_i}{\pi^2} - \frac{n - \sum_{i=1}^n X_i}{(1 - \pi)^2} < 0,$$

on déduit que le MLE de π est donné par

$$\hat{\pi}_{\text{MLE}} := \bar{X}_n.$$

On déduit également de la stricte concavité de la vraisemblance que le MLE contraint à la région $H_0 = \{\pi \leq \lambda_0\}$ vaut $\hat{\pi}_{\text{MLE}}$ si ce dernier est plus petit que π_0 et vaut π_0 sinon. On déduit que

$$\begin{aligned} \Lambda_n &= \begin{cases} \frac{L_n(\pi_0)}{L_n(\hat{\pi}_{\text{MLE}})} & \text{si } \hat{\pi}_{\text{MLE}} \geq \pi_0 \\ 1 & \text{sinon} \end{cases} \\ &= \begin{cases} \left(\frac{n\pi_0}{T_n}\right)^{T_n} \left(\frac{n-n\pi_0}{n-T_n}\right)^{n-T_n} & \text{si } T_n \geq n\pi_0 \\ 1 & \text{si } T_n < n\pi_0, \end{cases} \end{aligned}$$

où l'on a posé $T_n := \sum_{i=1}^n X_i$.

- (b) Il suffit de montrer que la fonction $g : [n\pi_0, n] \rightarrow (0, 1]$ définie par $g(t) := (n\pi_0/t)^t [(n - n\pi_0)/(n - t)]^{n-t}$ est décroissante. Pour cela, comme pour l'exercice précédent, montrons que la composition $\log \circ g$ est décroissante. On calcule pour tout $t \in [n\pi_0, n)$,

$$\partial_t \log(g(t)) = \partial_t \left\{ t \log\left(\frac{n\pi_0}{t}\right) + (n - t) \log\left(\frac{n - n\pi_0}{n - t}\right) \right\} = \log\left(\frac{n\pi_0}{t}\right) - \log\left(\frac{n - n\pi_0}{n - t}\right) \leq 0.$$

- (c) Afin de réaliser le test au niveau $\alpha = 0.05$, il faut trouver une région de rejet telle que la probabilité de commettre une erreur de type I est au maximum α . Il suit des calculs précédents que pour $c \in (0, 1)$, la région de rejet peut s'écrire

$$\{\Lambda_n \leq c\} = \{T_n \geq b\},$$

pour un certain $b \in (n\pi_0, n)$. Soit $\pi \in H_0 = \{\pi \leq \pi_0\}$. Alors, on a $T_n | \pi \sim \text{Bin}(n, \pi)$ et on peut montrer, comme à l'exercice précédent,

$$\sup_{\pi \leq \pi_0} P(T_n \geq b | \pi) = P(T_n \geq b | \pi_0),$$

pour n'importe quel $b \in (n\pi_0, n)$. Ainsi, si l'on prend $b = b(\alpha)$ comme étant le quantile d'ordre $\alpha = 0.95$ d'une Binomiale $\text{Bin}(n, \pi_0)$, on est certain que le test est de niveau alpha. On trouve

$$b(0.05) = \text{qbinom}(0.95, \text{size} = 50, \text{prob} = 0.5) = 31,$$

et comme $t_n < 31$, on ne rejette pas H_0 pour un tel choix de α .

- (d) La région critique associée à ce nouveau test aurait été déterminée par

$$\tilde{b}(0.05) = \text{qbinom}(0.95, \text{size} = 100, \text{prob} = 0.5) = 58.$$

Puisque maintenant on a $t_n = 59$, on aurait rejeté H_0 , bien que la probabilité de succès estimée sur les données est restée identique, à savoir $\hat{\pi} = 0.59$. Cela provient du fait que, comme la taille d'échantillon n a augmenté, le test a gagné en puissance.

Exercice 3

- (a) Par souci de clarté, notons $\theta_0 = \theta_X = \theta_Y$ la valeur commune du paramètre sous H_0 . La statistique de test $\Lambda_{n,m}$ est donnée par

$$\Lambda_{n,m} = \frac{\sup_{\theta_0} L_{n,m}(\theta_0, \theta_0)}{\sup_{\theta_X, \theta_Y} L_{n,m}(\theta_X, \theta_Y)},$$

où $L_{n,m}$ est la vraisemblance jointe de l'échantillon joint $(X_1, \dots, X_n, Y_1, \dots, Y_m)$ donnée par

$$L_{n,m}(\theta_X, \theta_Y) = \theta_X^{-n} \exp\left(-\frac{\sum_{i=1}^n X_i}{\theta_X}\right) \times \theta_Y^{-m} \exp\left(-\frac{\sum_{j=1}^m Y_j}{\theta_Y}\right).$$

On montre assez facilement, en utilisant des arguments similaires à ceux utilisés précédemment, que les MLE non contraints au dénominateur sont donnés par

$$\hat{\theta}_X = \bar{X}_n \quad \text{et} \quad \hat{\theta}_Y = \bar{Y}_m,$$

et que le MLE contraint du numérateur est donné par

$$\hat{\theta}_0 = \frac{\sum_{i=1}^n X_i + \sum_{j=1}^m Y_j}{n+m},$$

qui, intuitivement, est l'estimateur que l'on s'attend à obtenir sous H_0 puisque sous cette hypothèse, les deux exponentielles ont le même paramètre et on peut estimer ce paramètre commun en joignant toutes les données. Ainsi, on obtient

$$\begin{aligned} \Lambda_{n,m} &= \frac{\left(\frac{\sum_{i=1}^n X_i + \sum_{j=1}^m Y_j}{n+m}\right)^{-(n+m)} \exp(-(n+m))}{\left(\frac{\sum_{i=1}^n X_i}{n}\right)^{-n} \left(\frac{\sum_{j=1}^m Y_j}{m}\right)^{-m} \exp(-(n+m))} \\ &= \frac{(n+m)^{n+m}}{n^n m^m} \frac{(\sum_{i=1}^n X_i)^n (\sum_{j=1}^m Y_j)^m}{\left(\sum_{i=1}^n X_i + \sum_{j=1}^m Y_j\right)^{n+m}} \\ &= \frac{(n+m)^{n+m}}{n^n m^m} T_{n,m}^n (1 - T_{n,m})^m. \end{aligned}$$

(b) Définissons la fonction $g : t \in [0, 1] \mapsto g(t) := \frac{(n+m)^{n+m}}{n^n m^m} t^n (1-t)^m$ qui est telle que

$$\Lambda_{n,m} = g(T_{n,m}).$$

Soit $c \in (0, 1)$. On cherche à réécrire la région de rejet $\{\Lambda_{n,m} \leq c\}$ comme une région de rejet sur $T_{n,m}$. Pour cela, notons que la fonction g satisfait $g(0) = g(1) = 0$, que l'unique solution de l'équation de premier ordre $g'(t_0) = 0$ est donnée par

$$t_0 := \frac{n}{n+m} \in (0, 1),$$

et que $g''(t_0) < 0$. Ainsi, on déduit que

$$\{\Lambda_{n,m} \leq c\} = \{g(T_{n,m}) \leq c\} = \{T_{n,m} \leq a\} \cup \{T_{n,m} \geq b\},$$

pour $0 < a < b < 1$. Soit $\alpha \in (0, 1)$. On cherche $a = a(\alpha)$ et $b = b(\alpha)$ tels que

$$P(\{T_{n,m} \leq a\} \cup \{T_{n,m} \geq b\} \mid H_0) \leq P(T_{n,m} \leq a \mid H_0) + P(T_{n,m} \geq b \mid H_0) \leq \alpha$$

Comme $T_{n,m} \mid H_0 \sim \text{Beta}(n, m)$, si l'on souhaite répartir les probabilités d'erreur de type I de manière symétrique, on prendra respectivement comme valeurs de $a(\alpha)$ et $b(\alpha)$ les quantiles d'ordre $\alpha/2$ et $1 - \alpha/2$ d'une distribution Beta $\text{Beta}(n, m)$.

(c) Pour de telles valeurs, on a

$$\begin{aligned} a(0.05) &= \text{qbeta}(0.025, \text{shape1} = 35, \text{shape2} = 40) = 0.356 \\ b(0.05) &= \text{qbeta}(0.975, \text{shape1} = 35, \text{shape2} = 40) = 0.579, \end{aligned}$$

et l'on voit que $t_{n,m} > b(0.05)$, ce qui nous permet de conclure au rejet de H_0 .

Exercice 4

- (a) La statistique de test Λ_n est donnée par

$$\Lambda_n = \frac{\sup_{\nu} L_n(1, \nu)}{\sup_{\theta, \nu} L_n(\theta, \nu)}.$$

En faisant un graphique de la vraisemblance $L_n(\theta, \nu) = \theta^n \nu^{n\theta} (\prod_{i=1}^n X_i)^{-(\theta+1)} \mathbf{I}(\nu \leq X_{(1)})$, on voit facilement que peu importe la valeur de θ , le paramètre ν qui maximise la vraisemblance est

$$\hat{\nu} := X_{(1)}.$$

Dès lors, la log-vraisemblance profilée en θ est donnée par

$$\ell_n^p(\theta) = n \log(\theta) + n\theta \log(X_{(1)}) - (\theta + 1) \sum_{i=1}^n \log(X_i).$$

En résolvant la condition de premier ordre et en observant que pour tout θ , on a $\partial_{\theta}^2 \ell_n^p(\theta) < 0$, on trouve que la valeur de θ qui maximise cette expression est donnée par

$$\hat{\theta} := \frac{n}{\sum_{i=1}^n \log(X_i/X_{(1)})} = \frac{n}{T_n}.$$

Ainsi, on déduit

$$\begin{aligned} \Lambda_n &= \frac{T_n^n (\prod_{i=1}^n X_i)^{(n-T_n)/T_n}}{n^n X_{(1)}^{n(n-T_n)/T_n}} \\ &= \frac{T_n^n}{n^n} \exp\left(-\frac{T_n - n}{T_n} T_n\right) \\ &= \frac{T_n^n}{n^n} \exp(-T_n + n). \end{aligned}$$

- (b) Soit la fonction $g : t \in [0, \infty) \mapsto g(t) := t^n/n \times \exp(-t + n)$ telle que $\Lambda_n = g(T_n)$. Notons que g satisfait $g(0) = \lim_{t \rightarrow \infty} g(t) = 0$, que l'unique solution strictement positive de l'équation de premier ordre $g'(t_0) = 0$ est donnée par $t_0 = n$ et que $g''(t_0) < 0$. Dès lors, on déduit que pour tout $c \in (0, 1)$,

$$\{\Lambda_n \leq c\} = \{g(T_n) \leq c\} = \{T_n \leq a\} \cup \{T_n \geq b\},$$

où $0 < a < b < \infty$. Soit $\alpha \in (0, 1)$. Afin d'obtenir un test de niveau α , il suffit (voir exercices précédents) de choisir $a = a(\alpha)$ et $b = b(\alpha)$ tels que

$$P(T_n \leq a | H_0) + P(T_n \geq b | H_0) \leq \alpha.$$

Ainsi, puisque $T_n | H_0 \sim \text{Gamma}(n-1, 1)$, un choix valide est de prendre respectivement pour a et b les quantiles d'ordre $\alpha/2$ et $1 - \alpha/2$ de la distribution Gamma $\text{Gamma}(n-1, 1)$.

- (c) Pour de telles valeurs, on a

$$a(0.05) = \text{qgamma}(0.025, \text{shape} = 25 - 1, \text{rate} = 1) = 15.377$$

$$b(0.05) = \text{qgamma}(0.975, \text{shape} = 25 - 1, \text{rate} = 1) = 34.511,$$

et l'on voit que $t_n > b(0.05)$, ce qui nous permet de conclure au rejet de H_0 .

Exercice 5

- (a) On rappelle que les statistiques des tests proposés sont données, respectivement, par

$$\begin{aligned} W_n &= I_n(\hat{\theta})(\hat{\theta} - \theta_0)^2 \\ R_n &= \frac{S_n(\theta_0)^2}{I_n(\theta_0)} \\ T_n &= 2 \left(\ell_n(\hat{\theta}) - \ell_n(\theta_0) \right), \end{aligned}$$

où $\hat{\theta}$ désigne le MLE de θ , $S_n(\theta) = \ell'_n(\theta)$ désigne le score et $I_n = -E[S'_n(\theta)] = -E[\ell''_n(\theta)]$ désigne l'information de Fisher de l'échantillon. Puisque toutes les quantités utiles au calcul de ces statistiques ont déjà été calculées précédemment pour la distribution $\text{Beta}(\theta, 2)$, nous nous contentons de les rappeler ici :

$$\begin{aligned}\ell_n(\theta) &= n(\log(\theta) + \log(\theta + 1)) + (\theta - 1) \sum_{i=1}^n \log(X_i) + \sum_{i=1}^n \log(1 - X_i) \\ \hat{\theta} &= \frac{-2 - \overline{\log(X)}_n - \sqrt{4 + \overline{\log(X)}_n^2}}{2\overline{\log(X)}_n} \\ S_n(\theta) &= n \frac{2\theta + 1}{\theta(\theta + 1)} + \sum_{i=1}^n \log(X_i) \\ I_n(\theta) &= n \frac{2\theta^2 + 2\theta + 1}{\theta^2(\theta + 1)^2}.\end{aligned}$$

(b) Puisque la distribution $\text{Beta}(\theta, 2)$ satisfait les hypothèses de normalité du MLE, on sait que sous H_0 ,

$$W_n, R_n, T_n \xrightarrow{d} \chi_1^2,$$

quand $n \rightarrow \infty$. Dès lors, pour un niveau $\alpha \in (0, 1)$ donné, les régions critiques des tests asymptotiques de niveau α basés sur ces statistiques sont toutes identiques et sont données par

$$\{x > 0 : x > \chi_{1;1-\alpha}^2\},$$

où $\chi_{1;1-\alpha}^2$ désigne le quantile d'ordre $1 - \alpha$ d'une distribution Chi-carrée χ_1^2 . Avec les données proposées, on calcule

$$\begin{aligned}w_n &= 7.248 \\ r_n &= 7.239 \\ t_n &= 8.377,\end{aligned}$$

et $\chi_{1;0.95}^2 = 3.84$, ainsi, les trois tests mènent au rejet de l'hypothèse nulle. Cela n'est pas étonnant puisque les trois tests sont asymptotiquement équivalents, i.e., leur décision sera identique avec probabilité 1 quand $n \rightarrow \infty$.

Exercice 6

(a) Comme pour l'exercice précédent, nous nous contentons de rappeler les quantités utiles au calcul des statistiques des trois tests proposés :

$$\begin{aligned}\ell_n(\theta) &= n(\log(2) - \log(\theta)) + \sum_{i=1}^n \log(X_i) - \frac{1}{\theta} \sum_{i=1}^n X_i^2 \\ \hat{\theta} &= \overline{X^2}_n \\ S_n(\theta) &= -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n X_i^2 \\ I_n(\theta) &= \frac{n}{\theta^2},\end{aligned}$$

où il est utile de noter, pour le calcul de l'information de Fisher, que $X^2 \sim \text{Exp}(\theta)$.

(b) Puisque la distribution considérée satisfait les hypothèses de normalité du MLE, on sait que sous H_0 ,

$$W_n, R_n, T_n \xrightarrow{d} \chi_1^2,$$

quand $n \rightarrow \infty$. Dès lors, pour un niveau $\alpha \in (0, 1)$ donné, les régions critiques des tests asymptotiques de niveau α basés sur ces statistiques sont toutes identiques et sont données par

$$\{x > 0 : x > \chi_{1;1-\alpha}^2\},$$

où $\chi_{1;1-\alpha}^2$ désigne le quantile d'ordre $1 - \alpha$ d'une distribution Chi-carrée χ_1^2 . Avec les données proposées, on calcule

$$w_n = 0.0106$$

$$r_n = 0.0104$$

$$t_n = 0.0105,$$

et $\chi_{1;0.95}^2 = 3.84$, ainsi, aucun des trois tests ne mène au rejet de l'hypothèse nulle. Cela n'est pas étonnant puisque les trois tests sont asymptotiquement équivalents, i.e., leur décision sera identique avec probabilité 1 quand $n \rightarrow \infty$. En particulier, le vecteur de données ayant mené à l'observation $\sum_{i=1}^n x_i^2 = 98.98$ a été généré à partir de la distribution avec $\theta = 1$.

Exercice 7

- (a) On rappelle que pour, tester de telles hypothèses, les statistiques des trois tests asymptotiques sont respectivement données par

$$\begin{aligned} W_n &= \left((\hat{\theta}_X, \hat{\theta}_Y) - (\theta_X^0, \theta_Y^0) \right)^T I_n(\hat{\theta}_X, \hat{\theta}_Y) \left((\hat{\theta}_X, \hat{\theta}_Y) - (\theta_X^0, \theta_Y^0) \right) \\ R_n &= S_n(\theta_X^0, \theta_Y^0)^T I_n^{-1}(\theta_X^0, \theta_Y^0) S_n(\theta_X^0, \theta_Y^0) \\ T_n &= 2 \left(\ell_n(\hat{\theta}_X, \hat{\theta}_Y) - \ell_n(\theta_X^0, \theta_Y^0) \right) \end{aligned}$$

Afin de calculer ces dernières, on vérifie aisément que

$$\begin{aligned} \ell_n(\theta_X, \theta_Y) &= -n(\log(\theta_X) + \log(\theta_Y)) - \frac{\sum_{i=1}^n X_i}{\theta_X} - \frac{\sum_{j=1}^n Y_j}{\theta_Y} \\ S_n(\theta_X, \theta_Y) &= n \left(\frac{\bar{X}_n - \theta_X}{\theta_X^2}, \frac{\bar{Y}_n - \theta_Y}{\theta_Y^2} \right)^T \\ (\hat{\theta}_X, \hat{\theta}_Y) &= (\bar{X}_n, \bar{Y}_n) \\ I_n(\theta_X, \theta_Y) &= n \begin{pmatrix} 1/\theta_X^2 & 0 \\ 0 & 1/\theta_Y^2 \end{pmatrix} \end{aligned}$$

Dès lors, quelques manipulations algébriques permettent de montrer que

$$\begin{aligned} W_n &= n \left\{ \frac{(\bar{X}_n - \theta_X^0)^2}{(\bar{X}_n)^2} + \frac{(\bar{Y}_n - \theta_Y^0)^2}{(\bar{Y}_n)^2} \right\} \\ R_n &= n \left\{ \frac{(\bar{X}_n - \theta_X^0)^2}{(\theta_X^0)^2} + \frac{(\bar{Y}_n - \theta_Y^0)^2}{(\theta_Y^0)^2} \right\} \\ T_n &= 2n \left\{ \log \left(\frac{\theta_X^0}{\bar{X}_n} \right) + \log \left(\frac{\theta_Y^0}{\bar{Y}_n} \right) + \frac{\bar{X}_n}{\theta_X^0} + \frac{\bar{Y}_n}{\theta_Y^0} - 2 \right\} \end{aligned}$$

Soit $\alpha \in (0, 1)$. Comme chacune de ces statistiques de test converge en distribution vers une distribution Chi-carrée χ_2^2 , la région de rejet est identique pour chaque test et vaut

$$\{x : x > \chi_{2;1-\alpha}^2\}$$

si l'on souhaite effectuer le test au niveau α .

- (b) L'avantage d'un tel test par rapport à deux tests indépendants sur θ_X et θ_Y est qu'il n'y a pas de correction de région de rejet (ou, de manière équivalente, de p-valeur) à effectuer pour garder le même niveau $\alpha = 0.025$. Par contre, évidemment, le test proposé ici, s'il rejette H_0 , ne permet pas de savoir de quel paramètre provient le rejet.

Exercice 8

Notons X_{ij} pour $i = 1, \dots, 200$ et $j = 1, \dots, 3$, la variable aléatoire qui vaut 1 si l'individu i dans le quartier j est pour le candidat A et qui vaut 0 sinon. Alors, on a $X_{ij} \sim \text{Be}(\pi_j)$ pour un certain $\pi_j \in (0, 1)$ et l'on souhaite effectuer le test

$$H_0 : \pi_1 = \pi_2 = \pi_3 \quad \text{contre} \quad H_1 : \exists j_1 \neq j_2, \quad \pi_{j_1} \neq \pi_{j_2}.$$

Ces hypothèses peuvent se réécrire sous la forme

$$H_0 : A(\pi_1, \pi_2, \pi_3)^T = (0, 0)^T \quad \text{contre} \quad H_1 : A(\pi_1, \pi_2, \pi_3)^T \neq (0, 0)^T,$$

où $A : \mathbb{R}^3 \rightarrow \mathbb{R}^2$ est l'opérateur linéaire défini par la matrice

$$A = \begin{pmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \end{pmatrix}.$$

En particulier, il s'agit d'un test (asymptotique) sur une hypothèse composée. Par conséquent, les statistiques des deux tests demandés sont données par

$$\begin{aligned} W_n &= (A(\hat{\pi}_1, \hat{\pi}_2, \hat{\pi}_3)^T)^T (A I_n^{-1}(\hat{\pi}_1, \hat{\pi}_2, \hat{\pi}_3) A^T)^{-1} (A(\hat{\pi}_1, \hat{\pi}_2, \hat{\pi}_3)^T) \\ T_n &= 2 (\ell_n(\hat{\pi}_1, \hat{\pi}_2, \hat{\pi}_3) - \ell_n(\tilde{\pi}_{1;0}, \tilde{\pi}_{2;0}, \tilde{\pi}_{3;0})), \end{aligned}$$

où l'on vérifie facilement que

$$\begin{aligned} (\hat{\pi}_1, \hat{\pi}_2, \hat{\pi}_3) &= (\overline{X_1}, \overline{X_2}, \overline{X_3}) \\ (\tilde{\pi}_{1;0}, \tilde{\pi}_{2;0}, \tilde{\pi}_{3;0}) &= (\overline{X}, \overline{X}, \overline{X}) \\ \ell_n(\pi_1, \pi_2, \pi_3) &= \sum_{j=1}^3 \left\{ \left(\sum_{i=1}^{200} X_{ij} \right) \log(\pi_j) + \left(200 - \sum_{i=1}^{200} X_{ij} \right) \log(1 - \pi_j) \right\} \\ I_n(\pi_1, \pi_2, \pi_3) &= n \begin{pmatrix} \frac{1}{\pi_1(1-\pi_1)} & 0 & 0 \\ 0 & \frac{1}{\pi_2(1-\pi_2)} & 0 \\ 0 & 0 & \frac{1}{\pi_3(1-\pi_3)} \end{pmatrix} \end{aligned}$$

où l'on a noté, pour $j = 1, \dots, 3$, $\overline{X_j} := (200)^{-1} \sum_{i=1}^{200} X_{ij}$ et $\overline{X} := (600)^{-1} \sum_{j=1}^3 \sum_{i=1}^{200} X_{ij}$. Quelques manipulations algébriques conduisent alors aux expressions suivantes pour les statistiques de test :

$$\begin{aligned} W_n &= 200 \frac{(\overline{X_1} - \overline{X_2})^2 (\overline{X_2}(1 - \overline{X_2}) + \overline{X_3}(1 - \overline{X_3})) + 2(\overline{X_1} - \overline{X_2})(\overline{X_2} - \overline{X_3})\overline{X_2}(1 - \overline{X_2})}{\overline{X_1}(1 - \overline{X_1})\overline{X_2}(1 - \overline{X_2}) + \overline{X_1}(1 - \overline{X_1})\overline{X_3}(1 - \overline{X_3}) + \overline{X_2}(1 - \overline{X_2})\overline{X_3}(1 - \overline{X_3})} \\ &\quad + n \frac{(\overline{X_2} - \overline{X_3})^2 (\overline{X_1}(1 - \overline{X_1}) + \overline{X_2}(1 - \overline{X_2}))}{\overline{X_1}(1 - \overline{X_1})\overline{X_2}(1 - \overline{X_2}) + \overline{X_1}(1 - \overline{X_1})\overline{X_3}(1 - \overline{X_3}) + \overline{X_2}(1 - \overline{X_2})\overline{X_3}(1 - \overline{X_3})} \\ T_n &= 2 \times 200 \sum_{j=1}^3 \left\{ \overline{X_j} \log \left(\frac{\overline{X_j}}{\overline{X}} \right) + (1 - \overline{X_j}) \log \left(\frac{1 - \overline{X_j}}{1 - \overline{X}} \right) \right\} \end{aligned}$$

Puisque la distribution des données satisfait les hypothèses de normalité du MLE, on sait que sous H_0 ,

$$W_n, T_n \xrightarrow{d} \chi_2^2,$$

quand $n \rightarrow \infty$. Dès lors, au niveau $\alpha = 0.05$, on doit comparer les valeurs observées des statistiques de test, données par

$$\begin{aligned} w_n &= 10.253 \\ t_n &= 10.535, \end{aligned}$$

au quantile $\chi_{2;0.95} = 5.99$ et l'on constate que H_0 , l'hypothèse d'égalité des proportions de votants en faveur du candidat A entre les trois régions est rejetée, peu importe le test utilisé.

Exercice 9

Notons que les hypothèses du test peuvent être réécrites comme

$$H_0 : A(\mu_X, \mu_Y, \sigma)^T = (\mu_X^0, \mu_Y^0)^T \quad \text{contre} \quad H_1 : A(\mu_X, \mu_Y, \sigma)^T \neq (\mu_X^0, \mu_Y^0)^T,$$

où $A : \mathbb{R}^3 \rightarrow \mathbb{R}^2$ est l'opérateur linéaire défini par la matrice

$$A = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}.$$

En particulier, il s'agit d'un test (asymptotique) sur une hypothèse composée. Par conséquent, les statistiques des deux tests demandés sont données par

$$W_n = (A(\hat{\mu}_X, \hat{\mu}_Y, \hat{\sigma})^T - (\mu_X^0, \mu_Y^0)^T)^T \left(A I_n^{-1}(\hat{\lambda}_X, \hat{\lambda}_Y) A^T \right)^{-1} (A(\hat{\mu}_X, \hat{\mu}_Y, \hat{\sigma})^T - (\mu_X^0, \mu_Y^0)^T)$$

$$T_n = 2(\ell_n(\hat{\mu}_X, \hat{\mu}_Y, \hat{\sigma})) - \ell_n(\tilde{\mu}_{X;0}, \tilde{\mu}_{Y;0}, \tilde{\sigma}_0),$$

où l'on vérifie facilement que

$$(\hat{\mu}_X, \hat{\mu}_Y, \hat{\sigma}) = \left(\bar{X}_n, \bar{Y}_n, \sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2 + \sum_{j=1}^n (Y_j - \bar{Y}_n)^2}{2n}} \right)$$

$$(\tilde{\mu}_{X;0}, \tilde{\mu}_{Y;0}, \tilde{\sigma}_0) = \left(\mu_X^0, \mu_Y^0, \sqrt{\frac{\sum_{i=1}^n (X_i - \mu_X^0)^2 + \sum_{j=1}^n (Y_j - \mu_Y^0)^2}{2n}} \right)$$

$$\ell_n(\mu_X, \mu_Y, \sigma) = -n(\log(2\pi) + 2\log(\sigma)) - \frac{1}{2\sigma^2} \left(\sum_{i=1}^n (X_i - \mu_X)^2 + \sum_{j=1}^n (Y_j - \mu_Y)^2 \right)$$

$$I_n(\mu_X, \mu_Y, \sigma) = n \begin{pmatrix} \frac{1}{\sigma^2} & 0 & 0 \\ 0 & \frac{1}{\sigma^2} & 0 \\ 0 & 0 & \frac{1}{\sigma^4} \end{pmatrix}$$

Quelques manipulations algébriques conduisent alors aux expressions suivantes pour les statistiques de test :

$$W_n = 2n^2 \frac{(\bar{X}_n - \mu_X^0)^2 + (\bar{Y}_n - \mu_Y^0)^2}{\sum_{i=1}^n (X_i - \bar{X}_n)^2 + \sum_{j=1}^n (Y_j - \bar{Y}_n)^2}$$

$$T_n = 2n \log \left(\frac{\sum_{i=1}^n (X_i - \mu_X^0)^2 + \sum_{j=1}^n (Y_j - \mu_Y^0)^2}{\sum_{i=1}^n (X_i - \bar{X}_n)^2 + \sum_{j=1}^n (Y_j - \bar{Y}_n)^2} \right)$$

Puisque la distribution considérée satisfait les hypothèses de normalité du MLE, on sait que sous H_0 ,

$$W_n, T_n \xrightarrow{d} \chi_2^2,$$

quand $n \rightarrow \infty$. Dès lors, pour un niveau $\alpha \in (0, 1)$ donné, les régions critiques des tests asymptotiques de niveau α basés sur ces statistiques sont toutes deux identiques et sont données par

$$\{x > 0 : x > \chi_{2;1-\alpha}^2\},$$

où $\chi_{2;1-\alpha}^2$ désigne le quantile d'ordre $1 - \alpha$ d'une distribution Chi-carrée χ_2^2 .

Exercice 10

(a) Notons que les hypothèses du test peuvent être réécrites comme

$$H_0 : A(\lambda_X, \lambda_Y)^T = 0 \quad \text{contre} \quad H_1 : A(\lambda_X, \lambda_Y)^T \neq 0,$$

où $A : \mathbb{R}^2 \rightarrow \mathbb{R}^1$ est l'opérateur linéaire défini par la matrice

$$A = (2, -1).$$

En particulier, il s'agit d'un test (asymptotique) sur une hypothèse composée. Par conséquent, les statistiques des trois tests demandés sont données par

$$\begin{aligned} W_n &= \left(A(\hat{\lambda}_X, \hat{\lambda}_Y)^T \right)^T \left(A I_n^{-1}(\hat{\lambda}_X, \hat{\lambda}_Y) A^T \right)^{-1} \left(A(\hat{\lambda}_X, \hat{\lambda}_Y)^T \right) \\ R_n &= S_n^T(\tilde{\lambda}_{X;0}, \tilde{\lambda}_{Y;0}) I_n^{-1}(\tilde{\lambda}_{X;0}, \tilde{\lambda}_{Y;0}) S_n(\tilde{\lambda}_{X;0}, \tilde{\lambda}_{Y;0}) \\ T_n &= 2 \left(\ell_n(\hat{\lambda}_X, \hat{\lambda}_Y) - \ell_n(\tilde{\lambda}_{X;0}, \tilde{\lambda}_{Y;0}) \right), \end{aligned}$$

où l'on vérifie facilement que

$$\begin{aligned} (\hat{\lambda}_X, \hat{\lambda}_Y) &= (\bar{X}_n, \bar{Y}_n) \\ (\tilde{\lambda}_{X;0}, \tilde{\lambda}_{Y;0}) &= \left(\frac{\bar{X}_n + \bar{Y}_n}{3}, \frac{2(\bar{X}_n + \bar{Y}_n)}{3} \right) \\ \ell_n(\lambda_X, \lambda_Y) &= -n(\lambda_X + \lambda_Y) + \left(\sum_{i=1}^n X_i \right) \log(\lambda_X) + \left(\sum_{j=1}^n Y_j \right) \log(\lambda_Y) - \left(\sum_{i=1}^n \log(X_i!) + \sum_{j=1}^n \log(Y_j!) \right) \\ S_n(\lambda_X, \lambda_Y) &= \left(\frac{\bar{X}_n}{\lambda_X} - 1, \frac{\bar{Y}_n}{\lambda_Y} - 1 \right)^T \\ I_n(\lambda_X, \lambda_Y) &= n \begin{pmatrix} \frac{1}{\lambda_X} & 0 \\ 0 & \frac{1}{\lambda_Y} \end{pmatrix} \end{aligned}$$

Quelques manipulations algébriques conduisent alors aux expressions suivantes pour les statistiques de test :

$$\begin{aligned} W_n &= n \frac{(2\bar{X}_n - \bar{Y}_n)^2}{4\bar{X}_n + \bar{Y}_n} \\ R_n &= n \frac{(2\bar{X}_n - \bar{Y}_n)^2}{2(\bar{X}_n + \bar{Y}_n)} \\ T_n &= 2n \left\{ \bar{X}_n \log \left(\frac{3\bar{X}_n}{\bar{X}_n + \bar{Y}_n} \right) + \bar{Y}_n \log \left(\frac{3\bar{Y}_n}{2(\bar{X}_n + \bar{Y}_n)} \right) \right\} \end{aligned}$$

(b) Puisque la distribution considérée satisfait les hypothèses de normalité du MLE, on sait que sous H_0 ,

$$W_n, R_n, T_n \xrightarrow{d} \chi_1^2,$$

quand $n \rightarrow \infty$. Dès lors, pour un niveau $\alpha \in (0, 1)$ donné, les régions critiques des tests asymptotiques de niveau α basés sur ces statistiques sont toutes identiques et sont données par

$$\{x > 0 : x > \chi_{1;1-\alpha}^2\},$$

où $\chi_{1;1-\alpha}^2$ désigne le quantile d'ordre $1 - \alpha$ d'une distribution Chi-carrée χ_1^2 . Avec les données proposées, on calcule

$$\begin{aligned} w_n &= 2.95 \\ r_n &= 2.77 \\ t_n &= 2.83, \end{aligned}$$

et $\chi_{1;0.95}^2 = 3.84$, ainsi, aucun des trois tests ne mène au rejet de l'hypothèse nulle. Cela n'est pas étonnant puisque les trois tests sont asymptotiquement équivalents, i.e., leur décision sera identique avec probabilité 1 quand $n \rightarrow \infty$.